

Relatório Técnico: Análise do Comportamento de Consumo e desempenho no E-commerce

Autor: Thiago Alvarenga | Data: agosto/2026

Fonte dos Dados: E-commerce Customer Behavior and Transactions Dataset (Kaggle)

| Link de Acesso: [[Kaggle Dataset](#)]

1. Introdução e Problematização

O mercado global de e-commerce em 2026 exige uma compreensão profunda do comportamento transacional, dinâmica de engajamento e métricas de retenção de clientes. À medida que o volume de dados operacionais cresce, torna-se crítico identificar como fatores geográficos, demográficos e operacionais afetam as taxas de conversão, ticket médio e Lifetime Value (LTV). Este estudo analisa o ecossistema de vendas online com base em dados sintéticos de alta fidelidade, mapeando gargalos na jornada do cliente, padrões de aquisição, sazonalidade e perfis de altíssimo valor (outliers).

Justificativa do Uso de Dados: Com uma estrutura relacional abrangendo mais de 100 mil transações e múltiplas dimensões de navegação, a análise intuitiva torna-se inviável. O processamento distribuído de dados (PySpark/Pandas) e a modelagem estatística permitem fundamentar tomadas de decisão estratégicas sobre alocação de logística, retenção por segmento e mitigação de perdas operacionais decorrentes de cancelamentos e reembolsos.

2. Metodologia de Coleta e Engenharia de Dados

Os dados utilizados neste relatório provêm do repositório público *E-commerce Customer Behavior and Transactions Dataset*, hospedado no Kaggle. Trata-se de um conjunto de dados composto por cinco tabelas relacionais sintéticas unificadas via `customer_id` e `product_id`.

Características do Design e Arquitetura dos Dados

O ecossistema abrange todo o ciclo de vida da compra: 10.000 clientes, 1.000 produtos distribuídos em 15 categorias analíticas, 120.000 transações, 80.000 sessões de navegação e 25.000 avaliações de produtos.

Devido ao expressivo volume de dados (ultrapassando 100 mil registros), a infraestrutura do projeto foi modelada para garantir escalabilidade, integridade e alta performance:

1. **Coleta e Armazenamento Bruto:** Os arquivos originais foram baixados do Kaggle e armazenados no **Google Drive** como repositório de dados brutos (*Raw Layer*).
2. **Processamento e ETL (Google Colab):** O pipeline de engenharia, tratamento de nulos, padronização e construção dos JOINS relacionais foi desenvolvido em Python no **Google Colab**.
3. **Consolidação em Parquet:** A tabela final unificada — contendo mais de 120 mil linhas e todas as métricas derivadas — foi exportada no formato colunar otimizado **Parquet** (part-00000-...parquet).
4. **Data Warehouse & BI (BigQuery e Looker Studio):** O arquivo Parquet foi carregado no **Google BigQuery**, servindo como camada analítica (*Data Warehouse*) que alimenta diretamente o dashboard interativo no **Looker Studio**.

As métricas foram tratadas via pipeline estruturado com separação de arquivos brutos, tabelas tratadas consolidadas e resumos estatísticos exportados.

Variável / Métrica	Descrição Técnica no Projeto	Média (Mean) / Valor Global
Faturamento Total Líquido	Faturamento consolidado gerado na base de dados	R\$ 5.443.248,04
Ticket Médio Geral	Valor médio gasto por transação efetuada (concluída)	R\$ 79,23
Volume de Pedidos	Total de requisições registradas no sistema	68,7 mil (pedidos válidos) / 120 mil transações totais
Páginas Vistas por Sessão	Média de navegação no site por visita	3,0 a 193,0 pág/sessão (variação por segmento)
Duração da Sessão	Tempo de permanência na plataforma por visita	89,0s a 578,0s (variação por segmento)

Diagnóstico de Duplicação e Inconsistência de Telemetria

Foi identificada uma inconsistência entre a tabela de transações e a tabela de sessões. O JOIN realizado apenas pela chave `id_cliente` resultou em duplicação de linhas, onde cada transação foi associada a todas as sessões do cliente. Esse comportamento sugere que a tabela de sessões não

possui granularidade suficiente para rastrear a jornada de compra, ou que houve perda de dados no rastreamento web.

- **Diagnóstico do Erro (Fan-out Effect):** Identificou-se que a realização de um JOIN direto entre as tabelas `transacoes` e `sessoes` através unicamente da chave `id_cliente` provocou uma explosão de linhas por Produto Cartesiano Indesejado. Cada transação individual foi replicada pela quantidade total de sessões associadas ao histórico do cliente (ex.: para o cliente C05855, uma única transação gerou 7 registros duplicados, inflacionando o faturamento retornado).
- **Análise de Inconsistência de Dados (Telemetria vs. ERP):** Ao validar as sessões do cliente C05855, constatou-se uma divergência temporal e comportamental entre a base de navegação e a base financeira. A tabela de `sessoes` apresenta sub-registro de conversões (possível falha de disparo do pixel de rastreamento no checkout ou uso de bloqueadores pelo usuário), enquanto a tabela `transacoes` contém o registro real dos pedidos concluídos.
- **Ação Corretiva Aplicada:** Para preservar a integridade dos indicadores financeiros e evitar a superestimação de receita, a tabela `transacoes` foi mantida como a fonte primária da verdade (*Single Source of Truth*). A integração da tabela de `sessoes` foi reestruturada por meio de agregação prévia por cliente (com métricas consolidadas como total de sessões, tempo médio e lista de dispositivos), garantindo a cardinalidade de 1:1 entre o cliente/transação e o histórico de navegação.
- **Tratamento de Limitações de Telemetria:** Foi identificada uma limitação nos dados: as tabelas de transações e sessões não possuem correspondência temporal direta para a maioria dos clientes. Isso indica que o rastreamento de navegação (sessões) não cobre todas as compras realizadas. Para as transações sem sessão ativa, os campos `dispositivo` e `canal` foram preenchidos como 'não_rastreado' e 'direto', respectivamente, garantindo a integridade da análise sem introduzir falsos positivos de atribuição.

Critério da Segmentação de Preço

Para a segmentação de preço, foram utilizados os percentis da distribuição de preços efetivamente vendidos: Baixo Custo $\leq 33,00$ (aproximadamente p50), Médio Custo $33,01 - 65,00$ (entre p50 e p75) e Alto Custo $> 65,00$ (acima de p75). Esta abordagem garante que os cortes reflitam a realidade do negócio e não valores arbitrários.

3. Análise Exploratória (EDA) e Distribuição Socioeconômica

A. Dinâmica Geográfica e Desempenho Regional

- **EUA e Reino Unido lideram a receita:** Os Estados Unidos concentram o maior faturamento líquido da operação (R\$ 2.124.285,38 em 47.067 transações totais), seguidos pelo Reino Unido (R\$ 675.408,99 em 14.184 transações).

- **Paridade de Ticket Médio:** O ticket médio concluído mantém-se notavelmente estável entre os diferentes países, variando de R\$ 77,27 (Canadá) e R\$ 77,66 (Austrália) até R\$ 82,78 (Reino Unido).
- **Eficiência Logística:** O custo médio de envio apresenta baixa variação entre os países (média entre R\$ 3,99 na Austrália e R\$ 4,12 no Japão), indicando precificação logística padronizada.

• B. Distribuição Demográfica por Gênero

- **Equilíbrio de Faturamento:** A base consumidora é dividida quase identicamente entre os públicos Feminino (45,3% da receita líquida, R\$ 2.468.045,08 em 54.589 transações; Ticket Médio R\$ 79,06) e Masculino (44,9% da receita líquida, R\$ 2.443.956,19 em 53.672 transações; Ticket Médio R\$ 79,49).
- **Demais Identidades:** Os segmentos "Não-Binário" e "Prefiro Não Dizer" somam juntos ~9,8% do faturamento líquido total (R\$ 271,3 mil e R\$ 260,0 mil, respectivamente), registrando o maior ticket médio individual no segmento não-binário (R\$ 80,66).

• C. Análise de Categoria e Faixa de Preço

- **Eletrônicos em Destaque:** A categoria de Eletrônicos é a maior geradora de receita líquida (R\$ 1.504.492,02), impulsionada pelo maior preço médio praticado (R\$ 195,67). Seguem-se Jóias (R\$ 727.779,93; preço médio R\$ 100,61) e Automotivo (R\$ 573.642,18; preço médio R\$ 83,47).
- **Volume vs. Valor:** Categorias como Alimentos e Livros registram alto volume de unidades vendidas (9.130 e 5.952 vendas, respectivamente), porém com menor faturamento líquido devido aos preços médios reduzidos (R\$ 11,54 e R\$ 14,83, respectivamente).
- **Gargalo nos Status de Pedidos:** A análise por status revela que apenas 57,3% dos pedidos são concluídos com sucesso (68.700 pedidos concluídos). Reembolsos (17.035 pedidos), cancelamentos (17.108 pedidos) e pendências (17.180 pedidos) absorvem uma fatia expressiva da operação em todas as faixas de custo (Baixo, Médio e Alto Custo).

• D. Análise do Funil e Comportamento de Navegação por Segmento

- **Segmento Destaque (Regular):** Constitui a maior base transacional com 40.084 pedidos, LTV médio de R\$ 1.095,18 e faturamento líquido de R\$ 1.808.827,45.
- **Profundidade de Engajamento VIP:** Clientes VIP passam em média 578 segundos no site e visualizam 193 páginas por sessão, gerando o maior LTV médio (R\$ 5.056,23). Em contrapartida, Visitantes Ocasionais navegam apenas 89 segundos e visualizam 3 páginas, gerando LTV médio de R\$ 788,30.

• E. Preferência de Métodos de Pagamento e Eficiência Financeira

- **Dominância dos Cartões:** O Cartão de Crédito é a principal modalidade de pagamento da operação, representando **34,6% do total de transações concluídas** (23.778 pedidos) e gerando **R\$ 1.881.671,47** em faturamento líquido. O Cartão de Débito ocupa a segunda posição (13.993 transações; R\$ 1.113.785,64).
- **Adoção de Carteiras Digitais (Wallets):** Juntas, as opções digitais (PayPal, Apple Pay e Google Pay) somam **27.450 pedidos concluídos**, respondendo por **R\$ 2.189.986,15** do faturamento líquido. Destaca-se o **Apple Pay**, que apresentou o maior ticket médio isolado entre todos os métodos (**R\$ 81,41**).
- **Subaproveitamento e Menor Ticket em Transferência Bancária:** A transferência bancária registrou a menor adoção (3.479 pedidos; R\$ 257.804,78 em faturamento) e o menor ticket médio da base (**R\$ 74,10**), sinalizando oportunidade de otimização de incentivos ou de UX no checkout para essa modalidade.

4. Relatório de Insights

A. Matriz de Correlações entre Variáveis

- **Páginas Vistas vs. Adições ao Carrinho ($r = +0,7836$):** Uma das correlações positivas mais fortes da base. Indivíduos que exploram mais páginas realizam proporcionalmente mais intenções de compra, evidenciando que estratégias de retenção na página aumentam a probabilidade de conversão.
- **LTV vs. Cancelamento ($r = -0,1991$):** Há uma correlação negativa clara entre o Lifetime Value do cliente e a taxa de cancelamento. Clientes com maior valor vitalício tendem a cancelar menos pedidos.
- **Ausência de Correlação Idade x Consumo:** A Idade apresentou correlação praticamente nula com o Valor Vitalício ($r = -0,000396$) e com o Valor Total ($r = -0,0057$), demonstrando que o comportamento de compra no e-commerce independe da faixa etária.
- **Impacto Inexpressivo de Descontos no Valor Total ($r = -0,0913$):** O desconto aplicado não gerou aumento diretamente proporcional no valor total da transação.

B. Perfil de Outliers de Alto Valor (Top 20 Clientes VIP)

A aplicação do critério estatístico (+3 Desvios Padrão acima da média) estabeleceu a linha de corte para Outliers em R\$ 7.672,10. Foram identificados exatamente 20 clientes de altíssimo valor, todos pertencentes ao segmento VIP:

- **Liderança do Ranking:** O cliente C04587 (33 anos, Estados Unidos) lidera o LTV acumulado com R\$ 9.353,25, seguido pelo cliente C08939 (48 anos, Reino Unido) com R\$ 9.320,91.
- **Distribuição Demográfica dos Outliers:** Os clientes de maior LTV encontram-se predominantemente nos Estados Unidos (10 dos 20 outliers), Reino Unido, França, Alemanha, Canadá, Austrália, México e Índia, variando entre 18 e 59 anos.

C. Sazonalidade e Comportamento Temporal

- **Pico de Final de Ano:** A análise da sazonalidade mensal demonstra uma aceleração constante das vendas a partir de setembro, atingindo o ápice nos meses de novembro e dezembro.
- **Estabilidade Operacional:** Nos primeiros dois quadrimestres (janeiro a agosto), os faturamentos mensais mantêm uma linha de base estável com leve retração no mês de fevereiro (faturamento líquido de R\$ 332,7 mil nos pedidos concluídos).

5. Visualizações e Engenharia do Dashboard

O dashboard analítico foi projetado no Looker Studio garantindo visualização intuitiva e alinhada às melhores práticas de BI:

- **Indicadores Principais (KPI Cards):** Exibição em destaque do Faturamento Total Líquido (R\$ 5,44 mi), Ticket Médio (R\$ 79,23), Total de Pedidos Concluídos (68,7 mil) e Segmento Destaque (Regular).
- **Evolução Temporal e Sazonalidade:** Gráfico de linha para acompanhamento do faturamento líquido ao longo do período e matriz detalhada por país e mês transacionado.
- **Distribuição Dimensional:** Gráfico de rosca para status dos pedidos (destacando os 57,3% concluídos) e distribuição por gênero (45,3% feminino, 44,9% masculino).
- **Análise por Categoria:** Gráfico de barras horizontais ordenado por volume financeiro líquido, destacando a liderança disparada do setor de Eletrônicos.

Recomendações Estratégicas Baseadas nos Achados:

- **Otimização de Checkout (Métodos de Pagamento):** Incentivar o uso do Apple Pay (que entrega o maior ticket médio: R\$ 81,41) e aplicar ações de UX/desconto na Transferência Bancária para elevar seu ticket médio atual de R\$ 74,10.
- **Combate ao Gargalo de Retenção:** Implementar réguas de comunicação e e-mails de recuperação para os 42,7% de pedidos não concluídos (soma de cancelados, reembolsados e pendentes).
- **Foco no Engajamento:** Como a correlação entre Páginas Vistas e Carrinho é forte ($r = +0,7836$), estratégias como recomendação de produtos relacionados e conteúdos interativos na página devem ser priorizadas para reter o usuário no site.

Para fins de auditoria, execução do pipeline de ETL e acompanhamento interativo do painel, os acessos estão configurados nos repositórios oficiais:

- **Dashboard Interativo (Looker Studio):** [\[Link do Looker Studio\]](#)